

Diplomatura

Inteligencia Artificial

Módulo 5:

Inteligencia Artificial Generativa

Unidad 2:

Modelos Generativos en el Lenguaje – Parte 01



Presentación

En esta unidad exploraremos a fondo los modelos generativos de lenguaje (Large Language Models o LLMs) y sus aplicaciones. Veremos cómo se entrenan estos modelos mediante preentrenamiento y ajuste fino (fine-tuning), evaluaremos su calidad y limitaciones, y analizaremos casos de uso en ámbitos creativos y de comunicación.



Objetivos

Que los participantes logren...

- **Comprender** las etapas de preentrenamiento y ajuste fino en los modelos generativos de texto.
- **Analizar** los fundamentos de las arquitecturas Transformer y su rol en los modelos de lenguaje.
- **Evaluar** la calidad y limitaciones de los modelos de lenguaje generativo mediante benchmarking.
- Identificar las principales limitaciones y desafíos técnicos de los LLMs.
- **Conocer** ejemplos concretos de aplicación en el ámbito creativo y comunicacional.



Bloques temáticos

1. Teoría del preentrenamiento y ajuste fino en modelos generativos de texto.
2. Calidad, benchmarking y limitaciones de los modelos de lenguaje generativo.
3. Estudio de casos y ejemplos de aplicación en el ámbito creativo y comunicacional.

Teoría del preentrenamiento y ajuste fino en modelos generativos de texto

Los modelos generativos de lenguaje se entrenan en dos fases principales: preentrenamiento y ajuste fino. En la etapa de preentrenamiento, el modelo (por ejemplo, un transformer tipo GPT) se expone a enormes conjuntos de datos de texto no etiquetado (por lo general, texto obtenido de Internet). El objetivo es que el modelo aprenda patrones estadísticos del lenguaje de forma no supervisada, prediciendo palabras ocultas o la siguiente palabra en una secuencia. De esta manera, el modelo adquiere un conocimiento amplio del idioma: vocabulario, sintaxis, semántica y cierta "comprensión" contextual básica a partir de la información distribuida en los datos.

Posteriormente, en la fase de ajuste fino (fine-tuning), el modelo preentrenado se entrena de manera supervisada en tareas o dominios específicos, con conjuntos de datos más pequeños y especializados. Aquí se ajustan los pesos del modelo para optimizar su desempeño en objetivos concretos. Por ejemplo, un LLM como GPT que ya fue preentrenado con texto genérico de Internet puede afinarse para ser un chatbot conversacional entrenándolo con ejemplos de diálogos de preguntas y respuestas.

Durante el ajuste fino, se utilizan técnicas de optimización (como descenso de gradiente) para refinar el comportamiento del modelo y alinearlo con la tarea deseada. En el caso de modelos como ChatGPT, después del ajuste fino supervisado también se aplica un ajuste fino con retroalimentación humana (RLHF, siglas de Reinforced Learning for Human Feedback) para mejorar la

calidad y veracidad de las respuestas, utilizando evaluaciones humanas como señal de recompensa. En resumen, el preentrenamiento le da al modelo un amplio conocimiento general del lenguaje, mientras que el ajuste fino moldea ese conocimiento hacia usos más concretos y útiles.

Modelos Fundacionales

Es importante notar que esta combinación de preentrenamiento masivo y ajuste fino específico es lo que caracteriza a los modelos fundacionales o base (foundation models). Primero se entrena un modelo grande en datos extensivos y luego se reutiliza esa base para múltiples fines, en lugar de entrenar un modelo desde cero para cada tarea. Esto es posible gracias a que el modelo preentrenado ya posee representaciones internas muy ricas del lenguaje que pueden adaptarse fácilmente. Esta estrategia ha demostrado ser muy eficiente en términos de tiempo y recursos, dado que el grueso del aprendizaje ocurre en la fase no supervisada de preentrenamiento.

Arquitectura Transformer

Durante el proceso de entrenamiento, típicamente se utiliza una arquitectura Transformer con mecanismos de auto-atención, lo que permite manejar dependencias a largo plazo en el texto. El modelo aprende a predecir la siguiente palabra dada una secuencia de entrada, asignando probabilidades a posibles continuaciones. Este entrenamiento en secuencias largas le permite capturar desde relaciones gramaticales básicas hasta conocimientos factuales presentes en los datos. Por ejemplo, después del preentrenamiento, GPT-3 o GPT-4 son capaces de generar texto coherente sobre infinidad de temas, porque han absorbido patrones de todos los estilos y contenidos en sus datos de entrenamiento.

En síntesis, un modelo generativo de lenguaje comienza su vida "leyendo" Internet (u otro gran corpus) para aprender cómo se estructura el lenguaje (preentrenamiento) y luego se especializa mediante datos más específicos y retroalimentación orientada (ajuste fino) para realizar tareas útiles como traducir, resumir, programar o mantener una conversación de chat de forma efectiva. Esta teoría del entrenamiento escalonado ha sido clave en el éxito de la IA generativa moderna.

Aprendizaje por Refuerzo con Retroalimentación Humana (RLHF)

El Aprendizaje por Refuerzo con Retroalimentación Humana (RLHF, por sus siglas en inglés Reinforcement Learning from Human Feedback) es una técnica de aprendizaje automático que combina métodos de aprendizaje por refuerzo con retroalimentación humana directa para optimizar el desempeño de modelos de lenguaje. A diferencia del entrenamiento supervisado tradicional, donde el modelo aprende de ejemplos etiquetados, RLHF permite capturar preferencias humanas subjetivas y complejas que son difíciles de especificar mediante funciones de recompensa algorítmicas predefinidas.

La técnica RLHF se popularizó a partir del trabajo de OpenAI con InstructGPT en 2022, que posteriormente sentó las bases para ChatGPT. Como explican Ouyang et al. (2022) en su artículo seminal "Training language models to follow instructions with human feedback", el proceso RLHF consta de tres fases principales que permiten alinear los modelos de lenguaje con las intenciones y preferencias de los usuarios.

Fase 1: Ajuste Fino Supervisado (Supervised Fine-Tuning, SFT)

En esta etapa inicial, se parte de un modelo preentrenado como GPT-3 y se recopila un conjunto de datos de demostraciones escritas por anotadores humanos. Para crear InstructGPT, OpenAI contrató a aproximadamente 40 anotadores a través de plataformas como Upwork y Scale AI. Estos anotadores recibieron prompts (tanto de usuarios de la API como escritos por ellos mismos) y debían generar respuestas que demostraran el comportamiento deseado del modelo. El modelo base se ajusta entonces mediante aprendizaje supervisado utilizando este dataset de pares prompt-respuesta de alta calidad. Esta fase permite al modelo aprender qué tipo de salidas esperan y desean los humanos ante diferentes tipos de consultas.

Fase 2: Entrenamiento del Modelo de Recompensa (Reward Model, RM)

En la segunda fase, se entrena un modelo de recompensa que aprende a predecir qué respuestas preferirían los evaluadores humanos. Para ello, se presenta al modelo de lenguaje (ya afinado en la Fase 1) un conjunto de prompts y se generan múltiples respuestas alternativas para cada prompt. Los anotadores humanos revisan y clasifican estas respuestas según su calidad, utilidad, veracidad y seguridad. Estas clasificaciones humanas se utilizan para entrenar el modelo de recompensa, que aprende a asignar puntajes altos a las respuestas que los humanos consideran mejores y puntajes bajos a las que consideran peores. Este modelo de recompensa captura de manera implícita las preferencias humanas sobre aspectos difíciles de formalizar, como el tono apropiado, la veracidad o la ausencia de contenido dañino.

Fase 3: Optimización mediante Aprendizaje por Refuerzo (PPO)

Finalmente, en la tercera fase se utiliza un algoritmo de aprendizaje por refuerzo llamado Proximal Policy Optimization (PPO) para optimizar el modelo de lenguaje utilizando el modelo de recompensa como función objetivo. El modelo de lenguaje genera respuestas que son evaluadas por el modelo de recompensa, y los parámetros del modelo se actualizan mediante descenso de gradiente para maximizar la recompensa esperada. Para evitar que el modelo se desvíe demasiado de su comportamiento original y genere texto incoherente, se mantiene una copia del modelo original y se penaliza mediante una métrica llamada divergencia KL (Kullback-Leibler) si las salidas se alejan excesivamente del modelo base. Esta restricción asegura que el modelo siga produciendo texto fluido y gramaticalmente correcto mientras optimiza las preferencias humanas.

Resultados y Efectividad de RLHF en ChatGPT

Los resultados del proceso RLHF fueron notables. Según los experimentos reportados por Ouyang et al. (2022), el modelo InstructGPT de 1.3 mil millones de parámetros entrenado con RLHF fue preferido por evaluadores humanos sobre el modelo GPT-3 de 175 mil millones de parámetros (100 veces más grande) en el 71% de los casos. Esto demuestra que la retroalimentación humana puede tener un impacto mayor en la calidad percibida que simplemente aumentar el tamaño del modelo. Además, InstructGPT mostró mejoras significativas en veracidad y reducciones en la generación de contenido tóxico, confirmando que RLHF ayuda a alinear los modelos con valores humanos de seguridad y utilidad.

ChatGPT, lanzado en noviembre de 2022, utiliza el mismo marco general de RLHF que InstructGPT pero con refinamientos adicionales y un dataset más extenso. OpenAI invirtió recursos considerables en la contratación de anotadores calificados y en la creación de datos de retroalimentación de alta calidad, lo cual es una de las razones por las que ChatGPT supera a otros modelos de lenguaje de tamaño similar en capacidad conversacional y seguimiento de instrucciones. El proceso iterativo de RLHF permite al modelo mejorar continuamente a medida que se recopila más retroalimentación, y los botones de "pulgar arriba" y "pulgar abajo" en la interfaz de ChatGPT son una forma de seguir recogiendo preferencias de los usuarios para futuras versiones del modelo.

En conclusión, RLHF representa un avance fundamental en la alineación de modelos de lenguaje con intenciones humanas. Al integrar retroalimentación humana directa en el ciclo de entrenamiento mediante aprendizaje por refuerzo, esta técnica permite crear asistentes de IA más útiles, seguros y alineados con valores humanos, convirtiendo modelos preentrenados de propósito general en herramientas especializadas capaces de seguir instrucciones complejas y mantener conversaciones coherentes y contextuales.

Calidad, benchmarking y limitaciones de los modelos de lenguaje generativo

A medida que los modelos generativos de lenguaje se han vuelto más poderosos, se ha prestado mucha atención a cómo evaluar su calidad y cuáles son sus limitaciones. La calidad de un LLM suele medirse mediante

benchmarking en diversas tareas lingüísticas: por ejemplo, pruebas de comprensión lectora, traducción, respuesta a preguntas de conocimiento, razonamiento matemático, etc. Se usan conjuntos de evaluación estandarizados (como SQuAD, SuperGLUE, BIG-Bench, MMLU, entre otros) donde se compara el desempeño del modelo con respuestas esperadas o con el desempeño humano. Métricas como la perplejidad (qué tan bien predice secuencias de texto), la exactitud en preguntas cerradas, o puntajes en exámenes simulados, ayudan a cuantificar la calidad. Modelos más nuevos como GPT-4o o GPT-5 tienden a superar a versiones anteriores en muchos de estos benchmarks, mostrando avances en calidad de salida.

No obstante, evaluar realmente la "inteligencia" o utilidad de un modelo es complejo. Uno de los desafíos es que los LLM pueden producir texto muy verosímil pero eso no garantiza que sea correcto o apropiado. Aquí es donde entran sus limitaciones fundamentales. A continuación, se enumeran y explican algunas de las principales limitaciones y retos asociados a los modelos de lenguaje generativo:

- **Alucinaciones:** Se denomina "alucinación" en IA a cuando el modelo genera con gran confianza una respuesta que no es cierta, es decir, información inventada o inexacta (openai.com). Este es quizás el problema más mencionado en LLMs como ChatGPT. Por ejemplo, el modelo podría dar una referencia bibliográfica que suena plausible pero que es completamente fabricada, o afirmar datos históricos incorrectos con tono autoritario. Las alucinaciones ocurren porque el objetivo del modelo es continuar el texto de la forma más probable, no verificar la verdad; si en su entrenamiento vio patrones que asocian cierta pregunta con cierto tipo de respuesta, puede generarla aunque sea falsa. Esto

representa un gran desafío para aplicaciones que requieren alta confiabilidad, ya que el modelo no tiene un mecanismo interno robusto para distinguir verdad de ficción (openai.com). Mitigar las alucinaciones suele requerir técnicas adicionales (como verificaciones con buscadores, penalizar respuestas si el modelo no está seguro, o entrenar para que responda "No lo sé" cuando corresponda).

- **Conocimiento limitado y actualización:** Los LLM preentrenados tienen un "conocimiento congelado" hasta la fecha de corte de sus datos de entrenamiento. No saben nada de eventos ocurridos posteriormente ni pueden acceder por sí mismos a información nueva (a menos que se les provea). Por ejemplo, un modelo entrenado con datos hasta 2021 desconoce sucesos de 2022 o 2023. Esto limita su uso para temas muy actuales. Soluciones a esto incluyen volver a entrenar o afinar el modelo con datos recientes, o complementar el modelo con herramientas de búsqueda (ver MCP más adelante). Pero de base, un LLM no tiene memoria de trabajo conectada a internet en tiempo real, por lo que puede quedarse desactualizado.
- **Sesgos en los datos y contenidos tóxicos:** Los modelos tienden a reflejar los sesgos presentes en sus datos de entrenamiento. Si la data tiene prejuicios (de género, raciales, ideológicos, etc.), el modelo puede reproducirlos en sus respuestas. Por ejemplo, podrían asociar ciertos roles profesionales más a un género que a otro, simplemente porque así lo indicaban las estadísticas de su corpus. Del mismo modo, pueden generar lenguaje inapropiado u ofensivo si fueron expuestos a ese tipo de contenido. Si bien en el ajuste fino se intenta mitigar esto filtrando datos o

aplicando RLHF (aprendizaje por retroalimentación humana) para penalizar sesgos y discursos de odio, no es posible eliminarlos por completo. Los LLM siguen enfrentando dificultades para evitar estereotipos o comentarios inapropiados en algunos casos, especialmente si el usuario los lleva a contextos delicados. La interpretabilidad limitada del modelo dificulta garantizar neutralidad absoluta.

- Falta de interpretabilidad ("caja negra"): Los modelos de lenguaje profundo son notoriamente opacos. No es sencillo entender por qué dieron una cierta respuesta o cuáles "razonamientos" siguieron internamente (datacamp.com). Cientos de miles de millones de pesos conectados hacen difusa la trazabilidad de decisiones. Esta falta de transparencia es problemática en aplicaciones donde se necesita explicar la decisión (por ejemplo, en dominios médicos, legales, etc. justificar por qué la IA recomendó algo). La investigación en interpretabilidad de LLMs está en curso, pero aún no hay soluciones claras.
- Complejidad computacional: Entrenar y ejecutar estos modelos requiere enormes recursos computacionales. Los modelos generativos más grandes (con cientos de miles de millones de parámetros) consumen muchísima VRAM y tiempo de cómputo (datacamp.com). Incluso su inferencia (uso para producir resultados) es costosa en entornos de producción, lo que plantea retos de escalabilidad y costo económico. Además, latencias pueden volverse un problema (tomar varios segundos

por respuesta) dependiendo de la infraestructura.

- Longitud de contexto limitada: Cada modelo tiene un tamaño máximo de ventana de contexto (por ejemplo, 2048 tokens, 4096 tokens, o en GPT-4 versiones avanzadas hasta 32k tokens). Esto significa que no puede "recordar" o procesar contextos arbitrariamente largos dentro de una misma consulta. Si se le proporciona un documento muy extenso como prompt, quizá deba resumirlo internamente o ignorar partes. Modelos con mayor contexto están apareciendo, pero siempre habrá un límite práctico. Esto afecta la capacidad de trabajar con documentos extensos de una sola vez.
- Sobreajuste o respuestas genéricas: Existe el riesgo de que el modelo se sobreajuste a patrones comunes de sus datos y genere respuestas muy estereotipadas o repetitivas en ciertos casos. Por ejemplo, tienden a terminar cuentos con moralejas típicas, o comenzar ensayos con frases similares. Aunque no memorizan casos exactos (en general), sí pueden caer en fórmulas comunes, lo que afecta la creatividad o diversidad de la generación.

En cuanto al benchmarking de estos modelos, los investigadores se esfuerzan por diseñar pruebas que expongan estas limitaciones. Por ejemplo, hacer preguntas trampas o ambiguas para ver si el modelo se atreve a adivinar (fomentando alucinación) o reconoce la incertidumbre. OpenAI reportó que incluso GPT-5 (un hipotético sucesor) seguiría alucinando, aunque menos, especialmente en problemas de razonamiento, porque los procedimientos estándar de entrenamiento incentivan conjeturar antes que abstenerse ante la

duda. Esta evaluación cualitativa es tan importante como los números cuantitativos.

En resumen, aunque los modelos de lenguaje generativo han logrado resultados impresionantes y calidad en muchas tareas, no están exentos de problemas. Debemos ser conscientes de que pueden dar respuestas incorrectas con gran confianza, reflejar sesgos, carecer de información actualizada, y actuar como cajas negras. Los desarrolladores y usuarios deben abordar estos modelos con precaución, implementando salvaguardas (filtros, verificaciones) y usando evaluaciones rigurosas para determinar en qué condiciones un modelo es fiable. Comprender sus limitaciones es fundamental para usarlos de manera responsable y efectiva.

LM arena: Benchmarks relevantes para el uso cotidiano

LM Arena (o lmarena.ai) es una plataforma creada por Hugging Face que tiene como objetivo principal evaluar y comparar el rendimiento de los Grandes Modelos de Lenguaje (LLMs), como GPT-4, Llama, Claude, etc., de una manera competitiva, pública y asistida por humanos.

Esencialmente, es un "campo de batalla" o "arena de lucha" (de ahí su nombre, "Arena") donde los usuarios humanos interactúan con modelos anónimos, y el modelo que ofrece la mejor respuesta es considerado el ganador.

Características:

1. Mecánica de Evaluación: La Prueba de Batalla

El corazón de LM Arena es su sistema de "batalla" de modelos:

- Interacción Humana (Anónima): Un usuario introduce un prompt (pregunta o instrucción).
- Dos Modelos Ocultos: Dos LLMs diferentes (seleccionados al azar del pool de modelos) generan respuestas a ese mismo prompt. El usuario no sabe qué modelo es A y qué modelo es B.
- Votación: El usuario lee las dos respuestas y vota por la que considera superior (más precisa, más útil, mejor escrita, etc.).

2. Clasificación (Leaderboard)

El resultado de estas batallas se utiliza para generar un Leaderboard (tabla de clasificación) dinámico.

- Sistema ELO: La puntuación de los modelos se calcula utilizando el sistema de clasificación ELO, el mismo que se usa en el ajedrez. Si un modelo con una puntuación alta pierde contra uno con una puntuación baja, la penalización para el perdedor y la ganancia para el ganador serán más significativas.
- Métricas Reales: A diferencia de las pruebas académicas que usan benchmarks fijos, LM Arena mide la preferencia real de los usuarios en escenarios de uso cotidiano.

3. Propósito Principal

LM Arena sirve a varios propósitos clave dentro de la comunidad de IA:

- Transparencia: Permite a la comunidad ver qué modelos (tanto de código abierto como propietarios) están funcionando mejor en tiempo real.

- Feedback del Mundo Real: Proporciona a los desarrolladores de modelos un feedback valioso sobre cómo sus creaciones son percibidas y utilizadas por el público.
- Democratización del Testing: Cualquiera con acceso a internet puede participar en la evaluación de los modelos.

Resumen Breve

LM Arena es la plataforma principal de Hugging Face para rankear LLMs basados en la opinión y preferencia de los usuarios humanos que votan por la mejor respuesta en batallas anónimas de modelos.

Estudio de casos y ejemplos de aplicación en el ámbito creativo y comunicacional

A pesar de sus limitaciones, los modelos generativos de texto han abierto un abanico de aplicaciones creativas y comunicacionales. Gracias a su capacidad para producir contenido coherente y contextualmente relevante, se han convertido en herramientas valiosas en áreas como la redacción, el marketing, la educación y la producción de contenido multimedia.

Asistencia en redacción y generación de contenido: Una de las aplicaciones más inmediatas es utilizar LLMs como asistentes para escribir textos. Por ejemplo, ChatGPT puede ayudar a redactar correos electrónicos, artículos de blog, informes o incluso piezas de ficción. Empresas y profesionales de la comunicación lo emplean para borradores de artículos, slogans publicitarios, posts en redes sociales y más, agilizando el proceso creativo. El modelo puede

proponer frases alternativas, corregir gramática o adaptar el tono del texto. Según reportes, integrar ChatGPT en flujos de trabajo ha permitido crear contenido de marketing y eslóganes novedosos con rapidez. Un equipo de publicidad podría pedirle ideas para el lanzamiento de un producto, obteniendo múltiples conceptos de campaña creativa en segundos. Del mismo modo, periodistas lo usan para generar primeros borradores de notas o para reformular oraciones complejas, mejorando la productividad en la redacción.

Generación de ideas y lluvia de ideas (brainstorming): En entornos creativos, estos modelos funcionan como sparrings de ideas. Dado un concepto inicial, pueden expandirlo o sugerir enfoques diferentes. Por ejemplo, un guionista con un bloqueo creativo podría pedir "¿qué giros de trama inesperados podría tener esta historia?" y el modelo propondrá varios escenarios plausibles. Equipos de diseño o innovación también aprovechan la IA generativa para explorar variaciones de un concepto: nombres posibles para una nueva marca, características originales para un producto, etc. ChatGPT y similares sirven como una fuente inagotable de propuestas, que luego el humano filtra y pule. Aunque no todas las ideas serán viables, esta colaboración hombre-máquina puede ampliar la creatividad al salir de los patrones habituales de pensamiento.

Asistencia en comunicaciones profesionales: En el ámbito empresarial, los LLM se utilizan para redactar comunicaciones internas y externas. Pueden elaborar cartas, resumir reuniones, convertir apuntes en un memo bien escrito o traducir documentos a otros idiomas manteniendo matices. Muchas compañías integran modelos generativos en sus sistemas de atención al cliente automatizada (chatbots) para responder consultas frecuentes de manera más natural. Un chatbot potenciado con GPT puede entablar conversaciones de soporte técnico básicas, proporcionando respuestas en lenguaje sencillo y empático, mejorando la experiencia del cliente. También se han usado en la

escritura de discursos o presentaciones: dado un conjunto de puntos clave, el modelo es capaz de generar un discurso cohesivo que el ejecutivo luego adapta a su estilo personal.

Educación y contenido personalizado: En el sector educativo y de capacitación, la IA generativa está demostrando ser útil para crear materiales. Por ejemplo, puede desarrollar explicaciones simplificadas de temas complejos, generar ejemplos adicionales para ilustrar un concepto, o incluso plantear preguntas tipo test con las respuestas, a modo de práctica para estudiantes. Un profesor puede pedir "explícame la teoría de la relatividad en términos sencillos" y obtener un párrafo didáctico que luego ajusta. Además, los chatbots pueden actuar como tutores virtuales, respondiendo dudas de alumnos de forma interactiva. Esto permite una especie de atención personalizada a estudiantes, quienes pueden consultar a la IA generativa para clarificar conceptos a cualquier hora. La IA, con el debido entrenamiento, puede adaptar el nivel de la explicación según la edad o el trasfondo del alumno.

Creatividad multimedia: Si bien los LLM por sí solos generan texto, se combinan con otras herramientas para potenciar la creatividad en medios audiovisuales. Por ejemplo, se pueden usar para escribir guiones que luego se transforman en videos animados, o para redactar descripciones de imágenes que un modelo generativo visual (como DALL-E) convertirá en ilustraciones. Un caso notable fue un experimento donde un youtuber hizo que un modelo similar a GPT-4 escribiera, narrara (mediante síntesis de voz) y editara un video completo (docs.kanaries.net). La IA generó el guion, la voz en off y hasta escogió cortes de video según instrucciones, demostrando que es posible automatizar partes de la producción de contenido multimedia. En el campo de la música y poesía, también se han empleado modelos de lenguaje para

componer letras de canciones o poemas en cierto estilo literario, brindando inspiración o borradores que artistas humanos luego refinan.

Comunicación corporativa y análisis de sentimientos: Otras aplicaciones incluyen resumir y analizar grandes volúmenes de textos provenientes del público (redes sociales, encuestas, etc.) para que las empresas entiendan la opinión de sus clientes. Los LLM pueden sintetizar miles de comentarios en unos cuantos insights o clasificar automáticamente reseñas por sentimiento (positivo, negativo, neutro). Esto apoya labores de comunicación corporativa y marketing, al medir la reacción a lanzamientos o campañas. Plataformas de gestión de redes pueden integrar IA para sugerir respuestas adecuadas a mensajes de usuarios en tono cordial y alineado con la voz de la marca.

En conclusión, los modelos generativos de lenguaje se han convertido en asistentes versátiles en campos creativos y comunicacionales. Permiten agilizar tareas de escritura, ofrecen fuentes de inspiración y aumentan la productividad al encargarse de primeros borradores o tareas repetitivas de comunicación (iaempresa.comibm.com). Si bien el ojo humano sigue siendo necesario para revisar, corregir y aportar el toque final (asegurando factualidad y adecuación), la IA genera un punto de partida valioso. El resultado es una colaboración donde la máquina proporciona volumen y variantes, y el humano criterio y curaduría. Esta sinergia está transformando profesiones creativas, liberando más tiempo para la parte estratégica o artística, mientras la IA asiste en la ejecución más mecánica de la generación de contenido.



Bibliografía utilizada y sugerida

- OpenAI. (2023). *Introducing ChatGPT and GPT models*. Disponible en: <https://openai.com>
- Devlin, J. et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. ACL.
- Vaswani, A. et al. (2017). *Attention Is All You Need*. NeurIPS.
- IBM. (2022). *Foundation Models in AI: A New Paradigm*. Disponible en: <https://www.ibm.com>
- Datacamp. (2023). *Interpretability and Bias in Large Language Models*. Disponible en: <https://www.datacamp.com>
- Kanaries. (2023). *Using AI for Creative Multimedia Production*. Disponible en: <https://docs.kanaries.net>